

Université Paris Cité

Master 1 MIAGE - Parcours Valorisation et protection
des données de l'entreprise en Apprentissage

Promotion : 2025 - 2026

RAPPORT

pour le projet Apprentissage Machine

sur le sujet

Analyse des pays européens



Réalisé par :

Massinissa BELHARET
Nesma TALEB
Walid DJEMA

Le 14 avril 2026

Table des matières

1	Introduction	2
1.1	Contexte général du projet	2
1.2	Objectifs du projet	2
2	Description des données	2
2.1	Présentation du jeu de données	2
2.2	Description des variables	3
2.3	Qualité des données	3
3	Analyse Exploratoire des Données (EDA)	3
3.1	Statistiques descriptives	3
3.2	Analyse univariée	4
3.2.1	Interprétation	6
3.3	Analyse de corrélation	7
4	Prétraitement des données	9
4.1	Normalisation — Centrage et Réduction	9
5	Analyse en Composantes Principales (ACP)	9
5.1	Choix du nombre de composantes	9
5.2	Contributions des variables	10
5.3	Cercle des corrélations et Plan factoriel	10
6	Clustering	12
6.1	Classification Hiérarchique Ascendante (CAH)	12
6.2	K-means et validation par la silhouette	12
6.3	Interprétation des clusters	13
7	Conclusion	14

1 Introduction

1.1 Contexte général du projet

Dans le cadre du module d'Apprentissage Machine, nous avons réalisé une analyse sur un jeu de données regroupant 27 pays européens décrits par 7 indicateurs socio-économiques mesurés en 2001. Ce jeu de données reflète la diversité des pays européens à travers des indicateurs variés couvrant la santé, l'économie, l'emploi et l'éducation.

1.2 Objectifs du projet

L'objectif de ce projet est d'appliquer les méthodes de data mining et d'apprentissage non supervisé sur ces données en suivant les étapes suivantes :

- Explorer et comprendre la structure des données
- Effectuer un prétraitement adapté
- Réduire la dimension des données par ACP
- Identifier des groupes homogènes de pays
- Interpréter et commenter les résultats obtenus

2 Description des données

2.1 Présentation du jeu de données

Le jeu de données contient 27 pays européens (individus) décrits par 7 variables quantitatives continues mesurées en 2001. Il n'existe pas de variable cible, ce qui nous oriente vers une approche de clustering pour découvrir la structure cachée des données.

Le tableau ci-dessous présente les 5 premières observations du jeu de données :

	esp_vie_F	mort_inf	activ_F	chom	pnb_hb	education	sante
pays							
Allemagne	74.8	4.4	48.8	8.2	26768.0	4.3	10.6
Autriche	75.4	4.8	49.0	4.1	29075.0	4.9	8.0
Belgique	75.1	5.0	42.3	7.3	27952.0	5.8	8.8
Chypre	75.3	5.6	50.9	3.8	12724.0	5.8	6.0
Danemark	74.5	5.3	73.8	4.5	30096.0	8.1	8.4

FIGURE 1 – Aperçu des 5 premières lignes du jeu de données

2.2 Description des variables

Le tableau ci-dessous détaille chaque variable, sa description et son unité de mesure. Les variables couvrent quatre dimensions principales : la **santé** (espérance de vie, mortalité infantile, dépenses de santé), l'**emploi** (taux d'activité féminine, taux de chômage), la **richesse économique** (PNB par habitant) et l'**éducation** (dépenses d'éducation).

Variable	Description	Unité
esp_vie_F	Espérance de vie des femmes en 2001	Années
mort_inf	Mortalité infantile pour 1000 naissances	‰ (pour mille)
activ_F	Taux d'activité féminine	%
chom	Taux de chômage (actifs de plus de 15 ans)	%
pnb_hb	PNB annuel par habitant	\$
education	Dépenses d'éducation en % du PNB	% du PNB
sante	Dépenses de santé en % du PNB	% du PNB

TABLE 1 – Description des variables du jeu de données

2.3 Qualité des données

Avant de procéder à l'analyse, nous avons vérifié la qualité du jeu de données. Comme le montre la figure ci-dessous, aucune valeur manquante n'a été détectée dans l'ensemble des variables, et aucun doublon n'a été trouvé. Les données sont donc complètes et prêtes pour l'analyse.

```

esp_vie_F    0
mort_inf     0
activ_F      0
chom         0
pnb_hb       0
education    0
sante        0
dtype: int64

```

FIGURE 2 – Vérification des valeurs manquantes

3 Analyse Exploratoire des Données (EDA)

3.1 Statistiques descriptives

Le tableau ci-dessous présente les principales statistiques descriptives de chaque variable, incluant les mesures de tendance centrale, de dispersion ainsi que les degrés d'asymétrie (skewness) et d'aplatissement (kurtosis).

	esp_vie_F	mort_inf	activ_F	chom	pnb_hb	education	sante
count	27.00	27.00	27.00	27.00	27.00	27.00	27.00
mean	73.31	5.79	50.65	7.65	22380.22	5.36	7.54
std	3.70	1.86	10.98	4.01	10288.31	1.16	1.63
min	64.50	3.40	22.90	2.40	7809.00	2.30	4.20
25%	72.25	4.55	46.55	4.45	12728.50	4.65	6.25
50%	75.00	5.30	50.90	7.40	26756.00	5.20	7.90
75%	75.50	6.05	53.55	9.45	28513.50	5.75	8.45
max	77.50	10.40	76.20	18.10	50410.00	8.10	10.70
skewness	-1.22	0.98	0.21	0.98	0.49	0.13	-0.09
kurtosis	0.37	-0.06	1.20	0.76	0.13	1.11	-0.45

FIGURE 3 – Statistiques descriptives des variables

3.2 Analyse univariée

Pour chaque variable, nous avons tracé un histogramme avec la courbe KDE pour visualiser la forme de la distribution, ainsi qu'un boxplot pour détecter les valeurs atypiques. L'histogramme permet d'analyser le degré d'asymétrie et d'aplatissement de chaque distribution, tandis que le boxplot permet d'identifier visuellement les outliers grâce aux points situés en dehors des moustaches.

La figure ci-dessous présente les histogrammes et boxplots de l'ensemble des 7 variables.




FIGURE 4 – Histogrammes et boxplots des 7 variables

Pour une identification précise des outliers, nous utilisons la méthode de l'**intervalle interquartile (IQR)** :

- **Seuil bas** = $Q1 - 1.5 \times IQR$
- **Seuil haut** = $Q3 + 1.5 \times IQR$

Toute valeur en dehors de ces seuils est considérée comme un **outlier**. Les outliers détectés sont les suivants :

- **esp_vie_F** : Estonie (64.9), Lettonie (64.5), Lituanie (65.9)
- **mort_inf** : Estonie (8.4), Hongrie (9.2), Lettonie (10.4), Lituanie (8.6), Slovaquie (8.6)
- **activ_F** : Danemark (73.8), Norvège (69.2), Suède (76.2) en haut — Italie (36.0), Malte (22.9) en bas
- **chom** : Pologne (18.1), Slovaquie (17.4)
- **education** : Danemark (8.1), Norvège (7.4) en haut — Grèce (2.3) en bas

3.2.1 Interprétation

L'analyse univariée révèle plusieurs observations importantes :

- **esp_vie_F — Espérance de vie des femmes** : la distribution présente une asymétrie à gauche ($\text{skewness} = -1.22$), indiquant que la plupart des pays affichent une espérance de vie comprise entre 72 et 77 ans. Trois pays se distinguent comme outliers bas : Estonie (64.9 ans), Lettonie (64.5 ans) et Lituanie (65.9 ans).
- **mort_inf — Mortalité infantile** : la distribution est asymétrique à droite ($\text{skewness} = 0.98$), avec une concentration des pays autour de valeurs faibles. Cinq pays dépassent le seuil haut : Estonie (8.4‰), Hongrie (9.2‰), Lettonie (10.4‰), Lituanie (8.6‰) et Slovaquie (8.6‰).
- **activ_F — Taux d'activité féminine** : distribution quasi symétrique ($\text{skewness} = 0.21$) centrée autour de 50%. On distingue deux pays avec un taux très faible : Italie (36.0%) et Malte (22.9%), et trois pays avec un taux très élevé : Danemark (73.8%), Norvège (69.2%) et Suède (76.2%).
- **chom — Taux de chômage** : distribution asymétrique à droite ($\text{skewness} = 0.98$). Deux pays se démarquent nettement avec des taux très élevés : Pologne (18.1%) et Slovaquie (17.4%).
- **pnb_hb — PNB par habitant** : distribution asymétrique à droite ($\text{skewness} = 0.49$), avec une majorité de pays à PNB modéré et quelques pays très riches. **Aucun outlier** détecté.
- **education — Dépenses d'éducation** : distribution quasi symétrique ($\text{skewness} = 0.13$), centrée autour de 5% du PNB. La Grèce se distingue avec un taux très faible (2.3%), tandis que le Danemark (8.1%) et la Norvège (7.4%) affichent les valeurs les plus élevées.
- **sante — Dépenses de santé** : c'est la variable la plus régulière de l'ensemble ($\text{skewness} = -0.09$). **Aucun outlier** détecté.

Gestion des outliers

Les outliers identifiés reflètent des réalités socio-économiques bien connues : les pays baltes peu développés, Malte avec une faible participation féminine au marché du travail, et les pays nordiques très avancés en matière d'égalité et d'éducation. Ces valeurs ne constituent pas des erreurs de mesure et nous choisissons de les **conserver**, leur suppression entraînerait une perte d'information précieuse sur la diversité européenne.

Observation sur les échelles

Une **forte hétérogénéité des échelles** est observée entre les variables : `pnb_hb` varie entre 7 809 \$ et 50 410 \$, tandis que `mort_inf` varie entre 3.4 et 10.4‰. Cette disparité des unités et des dispersions justifie l'utilisation d'une **ACP normée** lors de l'étape de prétraitement.

3.3 Analyse de corrélation

La matrice de corrélation de Pearson, visualisée sous forme de heatmap, révèle plusieurs relations importantes entre les variables.




FIGURE 5 – Matrice de corrélation — Heatmap

On distingue une **forte corrélation négative** entre `esp_vie_F` et `mort_inf` ($r = -0.86$) : les pays avec une espérance de vie élevée ont systématiquement une mortalité infantile faible. Des **corrélations modérées** sont également observées : `esp_vie_F` et `sante` ($r = 0.70$), `esp_vie_F` et `pnb_hb` ($r = 0.65$), confirmant que les pays plus riches investissent davantage en santé et bénéficient d'une meilleure espérance de vie. On note

aussi que `activ_F` et `education` sont corrélées ($r = 0.60$), suggérant que les pays qui investissent en éducation favorisent la participation féminine. À l'inverse, certaines paires ne présentent **aucune relation linéaire** : `activ_F` et `esp_vie_F` ($r = -0.00$), `pnb_hb` et `education` ($r = 0.00$).




FIGURE 6 – Pairplot — relations entre variables

Le pairplot confirme visuellement ces résultats : les nuages de points **allongés** correspondent aux corrélations fortes (ex : `esp_vie_F` vs `mort_inf`) ce qui indique une relation linéaire entre les deux variables, tandis que les nuages **circulaires ou dispersés** correspondent aux corrélations nulles (ex : `activ_F` vs `sante`). La présence de ces corrélations significatives confirme l'existence d'une **structure multivariée** dans les données, ce qui justifie le recours à l'ACP.

4 Prétraitement des données

4.1 Normalisation — Centrage et Réduction

Les variables du jeu de données sont hétérogènes en termes d'unités et de dispersions : `pnb_hb` est exprimé en dollars avec des valeurs allant jusqu'à 50 410 \$, tandis que `mort_inf` varie entre 3.4 et 10.4%. Cette disparité justifie l'application d'une **normalisation par centrage-réduction** avant l'ACP, correspondant à l'**ACP normée**.

Chaque variable est transformée selon la formule du z-score :

$$z = \frac{x - \bar{x}}{s} \quad (1)$$

où $\bar{x}$ est la moyenne et s l'écart-type de la variable. Après normalisation, toutes les variables ont une **moyenne nulle** et un **écart-type de 1**, ce qui les rend comparables entre elles indépendamment de leurs unités d'origine.

Les données normalisées montrent que les pays baltes (Estonie, Lettonie, Lituanie) présentent des valeurs fortement négatives pour `esp_vie_F` et fortement positives pour `mort_inf`, ce qui confirme leur profil atypique déjà identifié lors de l'analyse univariée.

5 Analyse en Composantes Principales (ACP)

5.1 Choix du nombre de composantes

Le tableau ci-dessous présente les valeurs propres et la variance expliquée par chaque composante principale.

Composante	Valeur propre	Variance expliquée (%)	Variance cumulée (%)
PC1	3.47	47.71	47.71
PC2	1.78	24.46	72.17
PC3	0.77	10.56	82.73
PC4	0.54	7.41	90.14
PC5	0.39	5.38	95.51
PC6	0.21	2.88	98.40
PC7	0.12	1.60	100.00

TABLE 2 – Valeurs propres et variance expliquée

Deux critères permettent de déterminer le nombre d'axes à retenir. Le **critère de Kaiser** stipule qu'on ne retient que les composantes dont la valeur propre est supérieure à 1 : seules PC1 (3.47) et PC2 (1.78) satisfont ce critère, PC3 (0.77) est écartée.

Le **critère du coude**, présenté dans le scree plot ci-dessous, confirme ce choix : la courbe montre une chute importante de PC1 (47.7%) à PC2 (24.5%), puis s'aplatit à partir de PC3 (10.6%).

Les deux critères convergent vers **2 composantes principales**, expliquant ensemble **72.17%** de la variance totale.




FIGURE 7 – Scree Plot — variance expliquée par composante

5.2 Contributions des variables

PC1 est dominé par `esp_vie_F`, `mort_inf`, `pnb_hb` et `sante`, toutes au-dessus de la contribution moyenne de 14.3%. PC1 représente donc un axe de **développement socio-économique**. PC2 est dominé par `education` (44%) et `activ_F` (41%), ce qui en fait un axe de **participation sociale et éducation**.




FIGURE 8 – Contributions des variables à PC1 et PC2

5.3 Cercle des corrélations et Plan factoriel

Le cercle des corrélations, illustré dans la figure ci-dessous, permet d'interpréter la relation entre les variables initiales et les axes factoriels. PC1 oppose clairement deux groupes de variables : d'un côté `esp_vie_F`, `sante` et `pnb_hb` (côté positif), caractérisant les pays riches et en bonne santé, et de l'autre `mort_inf` et `chom` (côté négatif), caractérisant les pays avec une mortalité infantile élevée et un chômage important. PC2 est quant à lui dominé par `education` et `activ_F` (côté positif), représentant un axe de participation sociale indépendant du niveau de richesse. On note également que `esp_vie_F` et `sante` sont très proches sur le cercle ($r = 0.70$), et que `mort_inf` et `esp_vie_F` sont à l'opposé ($r = -0.86$).




FIGURE 9 – Cercle des corrélations

Le plan factoriel des individus confirme ces interprétations et révèle trois groupes naturels : les pays d'**Europe de l'Est** (Lettonie, Estonie, Lituanie, Pologne, Slovaquie, Hongrie) situés à gauche, caractérisés par un faible développement économique ; les pays d'**Europe du Nord** (Danemark, Suède, Norvège) situés en haut à droite, avec un fort investissement en éducation et une bonne espérance de vie et les pays d'**Europe du Sud/Ouest** situés en bas à droite, avec un profil intermédiaire.




FIGURE 10 – Plan factoriel des individus

6 Clustering

6.1 Classification Hiérarchique Ascendante (CAH)

La CAH est appliquée sur les 2 composantes principales retenues lors de l'ACP, en utilisant le **critère de Ward**. La figure ci-dessous présente le dendrogramme obtenu. En coupant à une distance d'environ 5, on obtient **3 groupes** : les pays d'Europe de l'Est (Slovaquie, Pologne, Lituanie, Hongrie, Lettonie, Estonie), les pays d'Europe du Nord (Danemark, Norvège, Suède) et les pays d'Europe du Sud/Ouest (Grèce, Malte, Italie, Espagne, Portugal, France, Belgique, Allemagne, Luxembourg, Suisse...). Ces groupes sont cohérents avec ce qu'on a observé dans le plan factoriel, ce qui nous amène à retenir $k = 3$, choix qui sera confirmé par le score de silhouette.




FIGURE 11 – Dendrogramme — CAH (critère de Ward)

6.2 K-means et validation par la silhouette

Afin de confirmer le choix de $k = 3$, nous calculons le score de silhouette pour k allant de 2 à 5. Les résultats obtenus sont les suivants : $k=2$ (0.572), $k=3$ (0.603), $k=4$ (0.488) et $k=5$ (0.472). Le score le plus élevé est obtenu pour $k=3$ (score = 0.603), ce qui confirme le résultat suggéré par la CAH. Les deux méthodes convergent donc vers $k=3$ comme nombre optimal de clusters.




FIGURE 12 – Score de silhouette selon k

Le K-means est ensuite appliqué avec $k=3$ sur les composantes principales. Les clusters obtenus sont les suivants :

- **Cluster 0** : Estonie, Hongrie, Lettonie, Lituanie, Pologne, Slovaquie
- **Cluster 1** : Allemagne, Autriche, Belgique, Chypre, Espagne, Finlande, France, Grèce, Irlande, Italie, Luxembourg, Malte, Pays Bas, Portugal, Royaume Uni, Slovénie, Suisse, Tchéquie
- **Cluster 2** : Danemark, Norvège, Suède

6.3 Interprétation des clusters

Le tableau des moyennes par cluster confirme les différences entre les groupes.

Cluster	esp_vie_F	mort_inf	activ_F	chom	pnb_hb	education	sante
0	67.28	8.88	50.75	11.68	10 211	5.47	5.38
1	74.86	5.03	46.88	6.84	24 944	4.94	8.14
2	76.07	4.17	73.07	4.43	31 338	7.60	8.27

TABLE 3 – Moyennes des variables par cluster

Cluster 0 — Europe de l’Est (6 pays) : ce groupe présente l’espérance de vie la plus faible (67.3 ans), une mortalité infantile élevée (8.9‰), un chômage important (11.7%) et un PNB faible (10 211 \$). Il s’agit des pays les **moins développés économiquement** de l’échantillon.

Cluster 1 — Europe Occidentale/Sud (18 pays) : ce groupe affiche une espérance de vie élevée (74.9 ans), une mortalité infantile modérée (5.0‰) et un PNB moyen (24 944 \$). Le taux d’activité féminine reste modéré (46.9%), ce qui caractérise des pays **développés à participation féminine intermédiaire**.

Cluster 2 — Europe du Nord (3 pays) : ce groupe se distingue par la meilleure espérance de vie (76.1 ans), la mortalité infantile la plus faible (4.2‰), un fort taux d’activité féminine (73.1%), un PNB élevé (31 338 \$) et les dépenses d’éducation les plus importantes (7.6%). Ce sont les pays les **plus développés avec une forte égalité de genre**.




FIGURE 13 – Clusters K-means sur le plan factoriel

7 Conclusion

Ce projet avait pour objectif d'analyser et de classer 27 pays européens à partir de 7 indicateurs socio-économiques, en appliquant des méthodes de data mining et d'apprentissage non supervisé.

L'analyse exploratoire a mis en évidence une forte hétérogénéité des données, avec des outliers représentant des pays aux profils extrêmes (pays baltes peu développés, pays nordiques très avancés). Ces outliers ont été conservés car ils reflètent la réalité socio-économique de ces pays en 2001. Une normalisation a ensuite été appliquée pour corriger la disparité des unités et des dispersions entre les variables.

L'ACP normée a permis de réduire la dimension des données en 2 composantes principales expliquant **72.17%** de la variance totale. PC1 représente un axe de **développement socio-économique** et PC2 un axe de **participation sociale et éducation**.

Le clustering, basé sur la CAH et confirmé par le score de silhouette (**k=3, score = 0.603**), a permis d'identifier 3 groupes distincts de pays européens :

- **Europe de l'Est** (6 pays) : pays peu développés, avec une mortalité infantile élevée et un PNB faible.
- **Europe Occidentale/Sud** (18 pays) : pays développés avec un profil intermédiaire.
- **Europe du Nord** (3 pays) : pays très développés, avec une forte égalité de genre et un investissement élevé en éducation.

Ces résultats sont cohérents avec ce qu'on sait de l'Europe de l'époque. La plupart des pays du cluster 0 ont depuis rejoint l'UE (2004), et il serait intéressant de refaire la même analyse avec des données de 2020 pour voir si l'écart s'est réduit.

Table des figures

1	Aperçu des 5 premières lignes du jeu de données	2
2	Vérification des valeurs manquantes	3
3	Statistiques descriptives des variables	4
4	Histogrammes et boxplots des 7 variables	5
5	Matrice de corrélation — Heatmap	7
6	Pairplot — relations entre variables	8
7	Scree Plot — variance expliquée par composante	10
8	Contributions des variables à PC1 et PC2	10
9	Cercle des corrélations	11
10	Plan factoriel des individus	11
11	Dendrogramme — CAH (critère de Ward)	12
12	Score de silhouette selon k	13
13	Clusters K-means sur le plan factoriel	14

Liste des tableaux

1	Description des variables du jeu de données	3
2	Valeurs propres et variance expliquée	9
3	Moyennes des variables par cluster	13